

Fundação Getulio Vargas

Metodologia de Survey e Aplicações Eleitorais

Professor Felipe Nunes

Tarefa I

Exercício 1: Amostragem

Autor: Joao Paulo Zangrandi

22 de julho de 2026

Objetivo

O exercício pede a comparação de três desenhos amostrais para estimar a proporção de pessoas alfabetizadas em Macaé (RJ), usando como população o arquivo `macae.rds`. A base contém 206.728 pessoas e, assumindo que ela representa corretamente a população do município, a proporção populacional de alfabetizados é:

Proporção populacional de alfabetizados: 0,8721

Foram simuladas 1.000 amostras para cada desenho. Em todos os casos, o tamanho final da amostra foi exatamente $n = 1200$. Para cada amostra simulada, calculei a média da variável alfabetizada; como a variável é binária, essa média é também a proporção de alfabetizados na amostra.

1. Amostragem Aleatória Simples

No primeiro desenho, usei uma amostragem aleatória simples (AAS) de pessoas. Em cada simulação, 1.200 indivíduos foram sorteados diretamente da base, sem reposição. Portanto, cada pessoa da população teve a mesma probabilidade de entrar na amostra.

Esse desenho é a referência natural para o exercício, pois não usa nenhuma informação auxiliar de distrito, subdistrito, bairro ou setor censitário. A variância das estimativas produzidas por ele serve como base para calcular o *design effect* dos outros dois desenhos.

2. Amostragem Estratificada

No segundo desenho, construí uma AAS com estratificação. A variável usada para definir os estratos foi `bairro`, transformada em quatro grupos. Primeiro, calculei a taxa média de alfabetização em cada bairro. Depois, agrupei os bairros em quatro estratos, de acordo com quartis dessa taxa: baixa, média baixa, média alta e alta alfabetização. Portanto, o número de estratos foi $h = 4$.

A escolha segue o critério substantivo da estratificação: criar grupos internamente mais homogêneos em relação à variável de interesse. Como o objetivo é estimar alfabetização, faz sentido formar estratos a partir de bairros com níveis parecidos de alfabetização.

A alocação da amostra foi proporcional ao tamanho populacional de cada estrato, isto é, $n_h \approx 1200 \times N_h/N$. Os valores finais foram ajustados por arredondamento para que a soma dos n_h fosse exatamente 1.200:

Estrato	População N_h	Amostra n_h
Baixa	92.191	535
Média baixa	25.312	147
Média alta	49.469	287
Alta	39.756	231
Total	206.728	1.200

3. Amostragem por Conglomerados

No terceiro desenho, usei os setores censitários como conglomerados, conforme pedido no enunciado. Fixei $n_i = 10$ entrevistas por setor censitário, que é o menor valor permitido pelo exercício e está dentro do intervalo de 10 a 20 entrevistas. Assim, para chegar a 1.200 entrevistas, foram sorteados 120 setores censitários:

$$120 \text{ setores} \times 10 \text{ entrevistas por setor} = 1200 \text{ entrevistas}$$

Dentro de cada setor sorteado, as pessoas foram selecionadas aleatoriamente. Usei apenas setores com pelo menos 10 pessoas registradas na base, para garantir que fosse possível fazer o sorteio sem reposição dentro de cada conglomerado. Com isso, cada repetição do desenho por conglomerados também produz exatamente $120 \times 10 = 1200$ pessoas.

Escolhi 10 entrevistas por setor porque isso aumenta o número de setores visitados. Em um desenho por conglomerados, entrevistar muitas pessoas no mesmo setor tende a aumentar a semelhança interna da amostra. Espalhar as entrevistas por mais setores ajuda a reduzir esse problema.

Resultados das simulações

A tabela abaixo resume as 1.000 simulações de cada desenho. O *design effect* foi calculado como a razão entre a variância amostral das 1.000 proporções simuladas no desenho analisado e a variância amostral das 1.000 proporções simuladas no desenho AAS:

$$DEFF_d = \frac{s^2(\hat{p}_d)}{s^2(\hat{p}_{AAS})}$$

Desenho	Média simulada	Variância simulada	Design effect
AAS	0,8720	0,00009591	1,000
Estratificada	0,8717	0,00008720	0,909
Conglomerados	0,8733	0,00011016	1,149

As três médias ficaram muito próximas da proporção populacional real, o que indica que os desenhos, como implementados nas simulações, não produziram viés relevante na estimativa média. A diferença principal aparece na dispersão das estimativas.




Figura 1: Distribuição das proporções estimadas em 1.000 simulações para cada desenho amostral.

Interpretação

O desenho estratificado produziu variância menor do que a AAS. O *design effect* foi 0,909, ou seja, a variância da estimativa estratificada ficou cerca de 9,1% abaixo da variância da AAS. Isso ocorre porque os estratos foram construídos a partir de uma característica associada à variável de interesse: a taxa média de alfabetização dos bairros. Quando os estratos são relativamente homogêneos por dentro e diferentes entre si, a estratificação reduz a oscilação das estimativas entre amostras.

O desenho por conglomerados produziu variância maior do que a AAS. O *design effect* foi 1,149, indicando uma variância aproximadamente 14,9% maior do que a variância da AAS. Esse resultado é esperado porque pessoas que vivem no mesmo setor censitário tendem a ser mais parecidas entre si do que pessoas sorteadas aleatoriamente em toda a cidade. Essa semelhança interna reduz a quantidade efetiva de informação trazida pela amostra.

Em termos práticos, a estratificação ajudou porque usou informação auxiliar relevante antes do sorteio. Já a amostragem por conglomerados aumenta a praticidade operacional, pois concentra entrevistas em setores sorteados, mas essa conveniência tem custo estatístico: a amostra fica menos dispersa geograficamente e, por isso, a variância tende a subir.

Conclusão

Entre os três desenhos, a AAS funciona como referência simples e neutra. A estratificação foi o desenho mais eficiente para esta base, pois reduziu a variância mantendo o tamanho da amostra em 1.200 pessoas. O desenho por conglomerados foi menos eficiente estatisticamente, mas é justificável em situações reais de campo, nas quais visitar setores selecionados pode reduzir custo, tempo e logística de coleta.