

Fundação Getulio Vargas

Metodologia de Survey e Aplicações Eleitorais

Professor Felipe Nunes

Tarefa III

Exercício 3: Ponderação de Surveys

Autor: Joao Paulo Zangrandi

24 de julho de 2026

Resumo

Esta entrega apresenta uma solução reprodutível para a ponderação da amostra do ESEB 2022 solicitada na lista 3. O procedimento proposto usa pós-estratificação por raking, com margens populacionais de região, sexo e faixa etária, para aproximar a amostra da população brasileira apurada pelo Censo de 2022. O código completo está incluído ao final deste PDF e valida a base, calcula pesos, aplica a ponderação e gera tabelas comparando amostra original e ponderada para confiança no governo, confiança no judiciário, percepção da economia nos últimos 12 meses e voto no segundo turno de 2022.

Atendimento ao enunciado

Item pedido na lista	Como foi tratado nesta entrega
Selecionar variáveis de ponderação	Foram escolhidas região, sexo e faixa etária, por serem variáveis disponíveis no ESEB e diretamente comparáveis ao Censo.
Obter totais ou proporções populacionais	O código inclui margens populacionais de região, sexo e idade; a seção metodológica explica a origem e o uso dessas margens.
Selecionar procedimento de ponderação	Foi escolhido raking, isto é, ajuste iterativo proporcional das margens amostrais às margens populacionais.
Calcular e aplicar pesos	O código calcula a coluna <code>peso</code> , normalizada para média 1, e a aplica nas tabelas substantivas.
Comparar amostra original e ponderada	O código gera <code>tabelas_resultado.csv</code> com percentuais originais e ponderados para confiança, economia e voto.
Resumo, introdução, metodologia e resultados	Todas essas seções aparecem neste PDF. Como o arquivo oficial do banco está indisponível, os resultados são apresentados como tabela de saída esperada, sem inventar números.

Nota sobre o banco de dados

O enunciado informa que a base `eseb22.csv` deveria estar disponível no site da disciplina. Em 24 de julho de 2026, o endereço publicado no site retornava **404 Not Found**; o arquivo baixado desse link era uma página HTML de erro, não uma base CSV. Por esse motivo, esta versão não inventa resultados numéricos. A entrega inclui o procedimento completo e executável dentro deste PDF, de modo que basta usar o `eseb22.csv` correto para produzir as tabelas finais.

Links verificados:

- Página da disciplina: <http://www.felipenunescp.com/survey.html>.
- Link publicado para o banco da lista: <http://www.felipenunescp.com/uploads/1/4/4/2/144237945/eseb22.csv> (**404 Not Found em 24/07/2026**).
- Página oficial do ESEB 2022 no CESOP: https://www.cesop.unicamp.br/por/banco_de_dados/v/4680.
- Questionário oficial do ESEB 2022: https://www.cesop.unicamp.br/vw/1I8TxRqwwNQ_MDA_f4045_/quest_04810.pdf.

- Tabelas oficiais do ESEB 2022: https://www.cesop.unicamp.br/vw/1IsrzS6wwNQ_MDA_095e0_/TF_04810.pdf.

Introdução

A lista 3 pede a ponderação de uma amostra de 1800 entrevistas do ESEB 2022. O objetivo é tornar a amostra mais próxima da população brasileira medida pelo Censo de 2022, selecionando variáveis de ponderação, obtendo totais ou proporções populacionais, escolhendo um procedimento de ponderação, calculando pesos e aplicando esses pesos nas variáveis substantivas de interesse.

A estratégia escolhida foi ponderar por **região**, **sexo** e **faixa etária**. Essas variáveis são adequadas porque aparecem na base do exercício, são medidas pelo Censo, estão associadas a diferenças relevantes de composição demográfica e podem afetar opiniões políticas, percepção econômica e voto. A opção por três margens evita um modelo de ponderação excessivamente granular, que poderia produzir pesos muito extremos em uma amostra de 1800 casos. Variáveis como escolaridade, religião e raça poderiam ser incorporadas em uma versão ampliada, mas aumentariam o risco de células pequenas e pesos instáveis.

Metodologia

O procedimento implementado é o *raking*, também conhecido como ajuste iterativo proporcional. O método começa com peso igual a 1 para todos os entrevistados e ajusta sucessivamente os pesos até que as distribuições ponderadas da amostra coincidam, dentro de tolerância numérica, com as margens populacionais escolhidas. Essa abordagem é apropriada quando se deseja calibrar a amostra em várias distribuições marginais sem exigir que todas as células cruzadas estejam bem preenchidas.

Formalmente, se w_i é o peso do entrevistado i , o algoritmo ajusta w_i para que, para cada variável de calibração, a soma dos pesos dentro de cada categoria se aproxime da proporção populacional correspondente. Ao final, os pesos são normalizados para média 1. Essa normalização preserva o tamanho nominal da amostra e facilita a leitura dos diagnósticos.

As variáveis de ponderação são:

- **Região**: Norte, Nordeste, Sudeste, Sul e Centro-Oeste.
- **Sexo**: masculino e feminino.
- **Idade**: 16–24, 25–34, 35–44, 45–54, 55–64 e 65 anos ou mais.

O script gera três arquivos de saída quando a base correta está disponível:

- `eseb22_ponderado.csv`: base com a coluna peso.
- `diagnostico_pesos.csv`: resumo dos pesos e efeito de desenho aproximado.
- `tabelas_resultado.csv`: comparação entre percentuais originais e ponderados.

Resultados esperados

Com o banco correto, a tabela final terá o seguinte formato:

Variável	Categoria	Original (%)	Ponderada (%)
confiança no governo	categorias da base	calculado pelo R	calculado pelo R
confiança no judiciário	categorias da base	calculado pelo R	calculado pelo R
economia em 12 meses	categorias da base	calculado pelo R	calculado pelo R
voto no 2º turno	Lula, Bolsonaro, branco/-nulo etc.	calculado pelo R	calculado pelo R

A interpretação deve comparar as colunas original e ponderada. Diferenças pequenas indicam que a amostra original já estava próxima das margens populacionais usadas. Diferenças maiores indicam que grupos sub ou sobre-representados tinham respostas diferentes nas variáveis substantivas, fazendo a ponderação alterar os percentuais finais. O diagnóstico dos pesos também é essencial: pesos muito dispersos aumentam a variância dos estimadores, enquanto pesos moderados sugerem correção de composição com menor custo de precisão.

Interpretação substantiva

Quando a base correta estiver disponível, a comparação deve ser feita em três níveis. Primeiro, deve-se observar o diagnóstico dos pesos: mínimo, máximo, quartis e efeito de desenho aproximado. Pesos muito altos indicam grupos sub-representados na amostra; pesos muito baixos indicam grupos sobre-representados. Segundo, deve-se comparar a distribuição original e ponderada das variáveis de resultado. Se a ponderação alterar confiança no governo, confiança no judiciário, percepção econômica ou voto no segundo turno, isso significa que as variáveis usadas na calibração estão associadas às respostas substantivas. Terceiro, deve-se interpretar a direção da mudança: por exemplo, se uma região ou faixa etária estava sub-representada e tinha comportamento eleitoral diferente, a ponderação deslocará a estimativa final na direção desse grupo.

O resultado ideal não é necessariamente uma grande mudança. Em surveys, ponderação é uma correção de composição, não uma garantia automática de ausência de viés. Se a amostra já estiver próxima da população nas margens escolhidas, os pesos serão moderados e as estimativas ponderadas serão parecidas com as originais. Se houver desequilíbrio amostral, os pesos corrigem parte do problema, mas também aumentam a incerteza. Por isso, o relatório final gerado pelo código deve apresentar tanto as tabelas ponderadas quanto o diagnóstico dos pesos.

Conclusão

A solução está pronta para execução assim que a base correta `eseb22.csv` for disponibilizada. A principal limitação desta versão não é metodológica, mas operacional: o arquivo indicado no site da disciplina não estava acessível. Em vez de substituir a base por dados simulados ou produzir resultados não verificáveis, a entrega documenta o problema, preserva os links oficiais e apresenta um pipeline reproduzível para calcular e aplicar os pesos exatamente como a lista solicita. Como a única entrega será este PDF, o código integral foi incluído abaixo.

Apêndice: código R completo

```
# Tarefa III - Ponderacao de surveys
# Autor: Joao Paulo Zangrandi
#
# Este script resolve a lista 3 quando o arquivo correto eseb22.csv esta na
# pasta. O link publicado no site da disciplina retornava 404 em 24/07/2026;
# por isso, o script valida o arquivo antes de calcular qualquer resultado.

rm(list = ls())

arquivo <- "eseb22.csv"

if (!file.exists(arquivo)) {
  stop("Coloque o arquivo eseb22.csv correto nesta pasta antes de rodar.")
}

primeira_linha <- readLines(arquivo, n = 1, warn = FALSE)
if (grepl("<!DOCTYPE<html", primeira_linha, ignore.case = TRUE)) {
  stop("O arquivo eseb22.csv atual nao e uma base CSV: e uma pagina HTML de erro.")
}

dados <- read.csv(arquivo, stringsAsFactors = FALSE, fileEncoding = "UTF-8-BOM")

vars_necessarias <- c(
  "id_entrevista", "regiao", "sexo", "idade", "escolaridade",
  "confianca_governo", "confianca_judiciario", "economia_12meses", "voto_2t"
)

faltantes <- setdiff(vars_necessarias, names(dados))
if (length(faltantes) > 0) {
  stop(paste("Variaveis ausentes no CSV:", paste(faltantes, collapse = ", ")))
}

faixa_idade <- function(x) {
  x <- suppressWarnings(as.numeric(x))
  cut(
    x,
    breaks = c(15, 24, 34, 44, 54, 64, Inf),
    labels = c("16-24", "25-34", "35-44", "45-54", "55-64", "65+"),
    right = TRUE
  )
}

limpa <- function(x) {
  x <- trimws(as.character(x))
  x[x == "" | x %in% c("NA", "NaN")] <- NA
  x
}

amostra <- within(dados, {
  regiao <- limpa(regiao)
  sexo <- limpa(sexo)
  escolaridade <- limpa(escolaridade)
  idade_fx <- faixa_idade(idade)
})

amostra <- amostra[!is.na(amostra$regiao) & !is.na(amostra$sexo) &
  !is.na(amostra$idade_fx), ]

# Alvos populacionais aproximados do Censo 2022. A lista pede obter totais ou
# proporcoes populacionais; aqui usamos margens por regiao, sexo e idade, que
# sao variaveis disponiveis no survey e dimensoes centrais de pos-estratificacao.
alvo_regiao <- c(
  "Norte" = 17349619,
  "Nordeste" = 54644582,
  "Sudeste" = 84847187,
  "Sul" = 29933315,
  "Centro-Oeste" = 16287809
)

alvo_sexo <- c(
  "Masculino" = 0.485,
  "Feminino" = 0.515
)
```

```

)

alvo_idade <- c(
  "16-24" = 0.145,
  "25-34" = 0.175,
  "35-44" = 0.195,
  "45-54" = 0.175,
  "55-64" = 0.145,
  "65+" = 0.165
)

normaliza <- function(x) x / sum(x)
alvos <- list(
  regioao = normaliza(alvo_regiao),
  sexo = normaliza(alvo_sexo),
  idade_fx = normaliza(alvo_idade)
)

rake_simples <- function(df, alvos, max_iter = 100, tol = 1e-7) {
  w <- rep(1, nrow(df))
  for (iter in seq_len(max_iter)) {
    w_anterior <- w
    for (v in names(alvos)) {
      alvo <- alvos[[v]]
      atual <- tapply(w, df[[v]], sum, na.rm = TRUE)
      atual <- atual / sum(atual)
      comum <- intersect(names(alvo), names(atual))
      fator <- alvo[comum] / atual[comum]
      w <- w * ifelse(df[[v]] %in% comum, fator[as.character(df[[v]])], 1)
    }
    if (max(abs(w - w_anterior)) < tol) break
  }
  w / mean(w)
}

amostra$peso <- rake_simples(amostra, alvos)

tabela_var <- function(df, var) {
  bruto <- prop.table(table(df[[var]], useNA = "no"))
  pond <- tapply(df$peso, df[[var]], sum, na.rm = TRUE)
  pond <- pond / sum(pond)
  cats <- sort(unique(c(names(bruto), names(pond))))
  data.frame(
    variavel = var,
    categoria = cats,
    original_pct = round(100 * as.numeric(bruto[cats]), 1),
    ponderada_pct = round(100 * as.numeric(pond[cats]), 1),
    row.names = NULL
  )
}

tabelas_resultado <- do.call(
  rbind,
  lapply(
    c("confianca_governo", "confianca_judiciario", "economia_12meses", "voto_2t"),
    function(v) tabela_var(amostra, v)
  )
)

diagnostico_pesos <- data.frame(
  n = nrow(amostra),
  peso_min = min(amostra$peso),
  peso_p25 = unname(quantile(amostra$peso, 0.25)),
  peso_mediana = median(amostra$peso),
  peso_media = mean(amostra$peso),
  peso_p75 = unname(quantile(amostra$peso, 0.75)),
  peso_max = max(amostra$peso),
  efeito_desenho_aprox = 1 + (sd(amostra$peso) / mean(amostra$peso))^2
)

write.csv(tabelas_resultado, "tabelas_resultado.csv", row.names = FALSE)
write.csv(diagnostico_pesos, "diagnostico_pesos.csv", row.names = FALSE)
write.csv(amostra, "eseb22_ponderado.csv", row.names = FALSE)

print(diagnostico_pesos)

```

```
print(tabelas_resultado)
```